

Análise Multivariada

Escalonamento Multidimensional

Prof. George von Borries

Departamento de Estatística
Universidade de Brasília

1 - 2026



Introdução

- Procedimento gráfico para redução de dimensionalidade.
- A ideia é representar n itens numa sistema de coordenadas de menor dimensão e utilizando distâncias d_{ij} que se aproximam das distâncias originais δ_{ij} entre itens.
- A principal medida utilizada é a distância Euclideana.
- As dissimilaridades podem ser também escores de julgamentos realizados por avaliadores, indicando o quanto dois objetos são parecidos.



Medidas de Dissimilaridade (d)

Para dois vetores $\mathbf{x}_i$ e $\mathbf{x}_k$ no espaço p -dimensional ($j = 1, \dots, p$), uma medida d_{ik} é definida como função de distância se

- $d_{ii} = d(\mathbf{x}_i, \mathbf{x}_i) = 0$;
- $d_{ik} = d(\mathbf{x}_i, \mathbf{x}_k) \geq 0$;
- $d_{ik} = d(\mathbf{x}_i, \mathbf{x}_k) = d(\mathbf{x}_k, \mathbf{x}_i) = d_{ki}$;
- Considere um outro vetor $\mathbf{x}_z$ no mesmo espaço p -dimensional
 - Métrica: $d(\mathbf{x}_i, \mathbf{x}_k) \leq d(\mathbf{x}_i, \mathbf{x}_z) + d(\mathbf{x}_z, \mathbf{x}_k)$.
 - Ultramétrica: $d(\mathbf{x}_i, \mathbf{x}_k) \leq \max\{d(\mathbf{x}_i, \mathbf{x}_z), d(\mathbf{x}_z, \mathbf{x}_k)\}$.



- Distâncias são dispostas numa matriz quadrada $(n \times n)$ denominada matriz de dissimilaridade,

$$\mathbf{D} = \begin{pmatrix} 0 & d_{12} & \cdots & d_{1n} \\ d_{21} & 0 & \cdots & d_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & 0 \end{pmatrix}$$

em que n é o número de observações.

- As distâncias são geralmente Euclidianas, i.e., sejam duas observações p -dimensionais, i.e.,

$$\mathbf{y}_i^T = [y_{i1}, y_{i2}, \dots, y_{ip}] \quad \text{e} \quad \mathbf{y}_j^T = [y_{j1}, y_{j2}, \dots, y_{jp}].$$

A distância Euclideana será

$$\delta_{ij} = [(\mathbf{y}_i - \mathbf{y}_j)^T (\mathbf{y}_i - \mathbf{y}_j)]^{1/2} = \left(\sum_{k=1}^p [y_{ik} - y_{jk}]^2 \right)^{1/2}$$



Escalonamento Multidimensional Métrico

(Análise de Coordenadas Principais)

Seja $\mathbf{D} = (\delta_{ij})$. Queremos encontrar n pontos em k dimensões tal que as distâncias d_{ij} nas k dimensões sejam aproximadamente iguais a δ_{ij} em $\mathbf{D}$. A seguir apresentamos os passos do algoritmo junto com dados de um exemplo¹ para melhor compreensão.

- 1 Considere uma matrix $\mathbf{D} = (\delta_{ij})$.

$$\mathbf{D} = \begin{pmatrix} 0 & 2\sqrt{2} & 2\sqrt{2} & 2\sqrt{2} & 2\sqrt{2} \\ 2\sqrt{2} & 0 & 4 & 4\sqrt{2} & 4 \\ 2\sqrt{2} & 4 & 0 & 4 & 4\sqrt{2} \\ 2\sqrt{2} & 4\sqrt{2} & 4 & 0 & 4 \\ 2\sqrt{2} & 4 & 4\sqrt{2} & 4 & 0 \end{pmatrix}$$

¹Dados do Exemplo 16.1.2 de Rencher e Christensen (2012).



- 2 Construa uma matriz $\mathbf{A} = (a_{ij}) = (-\frac{1}{2}\delta_{ij}^2)$.

$$\mathbf{A} = - \begin{pmatrix} 0 & 4 & 4 & 4 & 4 \\ 4 & 0 & 8 & 16 & 8 \\ 4 & 8 & 0 & 8 & 16 \\ 4 & 16 & 8 & 0 & 8 \\ 4 & 8 & 16 & 8 & 0 \end{pmatrix}$$

- 3 Construa uma matriz $\mathbf{B} = (b_{ij})$ (simétrica), com elementos $b_{ij} = a_{ij} - \bar{a}_{i.} - \bar{a}_{.j} + \bar{a}_{..}$. A matriz $\mathbf{B}$ pode ser escrita como

$$\mathbf{B} = \left(\mathbf{I} - \frac{1}{n} \mathbf{J} \right) \mathbf{A} \left(\mathbf{I} - \frac{1}{n} \mathbf{J} \right).$$

$$\mathbf{B} = \left(\mathbf{I} - \frac{1}{5} \mathbf{J} \right) \mathbf{A} \left(\mathbf{I} - \frac{1}{5} \mathbf{J} \right) = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 8 & 0 & -8 & 0 \\ 0 & 0 & 8 & 0 & -8 \\ 0 & -8 & 0 & 8 & 0 \\ 0 & 0 & -8 & 0 & 8 \end{pmatrix}$$



- 4 Obtenha da decomposição espectral $\mathbf{B} = \mathbf{V}\mathbf{U}\mathbf{V}^T$ em que $\mathbf{V}$ é a matriz de autovalores de $\mathbf{B}$ e $\mathbf{U}$ é a matriz diagonal de autovalores de $\mathbf{B}$. Mantenha somente os maiores (ou não nulos) autovalores e respectivos autovetores.

Para os dados do exemplo, $\lambda_1 = \lambda_2 = 16$ e

$$\mathbf{v}_1 = \begin{pmatrix} 0 \\ \frac{1}{2}\sqrt{2} \\ 0 \\ -\frac{1}{2}\sqrt{2} \\ 0 \end{pmatrix}, \quad \mathbf{v}_2 = \begin{pmatrix} 0 \\ 0 \\ \frac{1}{2}\sqrt{2} \\ 0 \\ -\frac{1}{2}\sqrt{2} \end{pmatrix}$$

Note que $\mathbf{B} = \mathbf{V}\mathbf{U}\mathbf{V}^T = \mathbf{V}\mathbf{U}^{1/2}\mathbf{U}^{1/2}\mathbf{V}^T = \mathbf{Z}\mathbf{Z}^T$ e para o exemplo


$$\mathbf{Z} = \left(\sqrt{\lambda_1}\mathbf{v}_1, \sqrt{\lambda_2}\mathbf{v}_2 \right) = \begin{pmatrix} 0 & 0 \\ 2\sqrt{2} & 0 \\ 0 & 2\sqrt{2} \\ -2\sqrt{2} & 0 \\ 0 & -2\sqrt{2} \end{pmatrix}$$



As linhas de $\mathbf{Z}$ são os pontos cujas as distâncias $d_{ij} = (\mathbf{z}_i - \mathbf{z}_j)^T(\mathbf{z}_i - \mathbf{z}_j)$ se aproximam dos δ_{ij} 's na matriz de distâncias original $\mathbf{D}$.

5 Represente graficamente as linhas de $\mathbf{Z}$.

```
# Valores arredondados para 2 casas com objetivo  
# de conferencia com resultados apresentados em aula.  
  
d <- round(matrix(c(0, 2*sqrt(2), 2*sqrt(2), 2*sqrt(2), 2*sqrt(2),  
                    2*sqrt(2), 0, 4, 4*sqrt(2), 4,  
                    2*sqrt(2), 4, 0, 4, 4*sqrt(2),  
                    2*sqrt(2), 4*sqrt(2), 4, 0, 4,  
                    2*sqrt(2), 4, 4*sqrt(2), 4, 0), 5, 5, byrow=T), 2)  
emdd <- cmdscale(d, eig=T, k=2)  
x <- round(emdd$points[,1], 2)  
y <- round(emdd$points[,2], 2)  
plot(x, y, col='blue', pch=19, xlab = "Dim. 1", ylab = "Dim. 2")
```



Escalonamento Multidimensional Não Métrico

- Neste caso a matriz de dissimilaridades é obtida de avaliações realizadas por julgadores.
- Os valores δ_{ij} são ordenados e procura-se uma função monótona que preserve esta ordem num espaço de menor dimensão, i.e.,

$$\delta_{ij} = f(d_{ij}), \text{ tal que } \delta_{ij} < \delta_{uv} \Rightarrow f(\delta_{ij}) < f(\delta_{uv}).$$

- O problema não tem solução única. Valores d_{ij} podem ser estimados por regressão monotônica, através de valores $\hat{d}_{ij}$ que minimizam a soma de quadrados ponderada

$$S^2 = \frac{\sum_{i < j} (d_{ij} - \hat{d}_{ij})^2}{\sum_{i < j} d_{ij}^2} \quad (\text{Medida de Stress})$$

sujeita a restrição de valores ordenados $\hat{d}_{ij}$.

- Ver Exemplo 5.3 no livro texto.

