



Universidade de Brasília
Departamento de Estatística

Análise de Correspondências

Carlos César Yoshitake
Prof. George Von Borries

Resolução da Lista 8 da disciplina Análise
Multivariada.

Brasília
2026

Índice

1	Questões	2
1.1	Questão 72	2
1.2	Questão 73	6
1.3	Questão 6.1 Artes e Barroso.	10
1.4	Questão 6.2 Artes e Barroso.	15
1.5	Questão 6.3 Artes e Barroso.	19
1.6	Questão 6.4 Artes e Barroso.	22
1.7	Questão 6.5 Artes e Barroso.	26
1.8	Questão 6.6 Artes e Barroso.	30
1.9	Questão 6.7 Artes e Barroso.	30
1.10	Questão 6.8 Artes e Barroso.	30
1.11	Questão 6.9 Artes e Barroso.	30

1 Questões

1.1 Questão 72

Pesquise sobre o pacote ca do R. Descreva os objetos da função ca (listados abaixo) e a relação com os resultados matriciais apresentados em sala. Reproduza estes objetos matricialmente.

Objetos da função ca: sv, rowmass, rowdist, rowinertia, rowcoord, colmass, coldist, colinertia, colcoord, N.

- SV (Singular Values)}

Descrição: valores singulares obtidos a partir da decomposição em valores singulares da matriz padronizada da Análise de Correspondência. Seus quadrados correspondem aos autovalores da análise e representam a inércia explicada por cada dimensão.

Fórmulas:

$$\mathbf{S} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{r}\mathbf{c}')\mathbf{D}_c^{-1/2}$$

$$\mathbf{S} = \mathbf{U}\mathbf{V}'$$

Os elementos da diagonal de Σ correspondem ao objeto **sv**.

$$\lambda_k = \sigma_k^2$$

- Rowmass (Massa das linhas)

Descrição: proporção de observações pertencentes a cada linha da tabela de contingência.

Fórmulas:

$$\mathbf{P} = \frac{\mathbf{N}}{n}$$

$$\mathbf{r} = \mathbf{P}\mathbf{1}$$

$$r_i = \sum_{j=1}^J p_{ij}$$

- Rowdist (Distâncias qui quadrado das Linhas)

Descrição: distância qui-quadrado entre cada perfil de linha e o perfil médio das colunas

Fórmulas:

$$d_i^2 = \sum_{j=1}^J \frac{\left(\frac{p_{ij}}{r_i} - c_j\right)^2}{c_j}$$

- Rowinertia (Inércia das Linhas)

Descrição: contribuição absoluta de cada linha para a inércia total.

Fórmulas:

$$I_i = r_i d_i^2$$

A inércia total é dada por:

$$I = \sum_i r_i d_i^2$$

- Rowcoord (Coordenada das Linhas)

Descrição: coordenadas fatoriais das categorias de linha nos eixos da análise.

Fórmulas:

$$\mathbf{F} = \mathbf{D}_r^{-1/2} \mathbf{U}$$

Cada linha de F representa a posição de uma categoria de linha no mapa perceptual.

- Colmass (Massas das Colunas)

Descrição: proporção de observações pertencentes a cada coluna da tabela de contingência.

Fórmulas:

$$\mathbf{c} = \mathbf{P}' \mathbf{1}$$

$$c_j = \sum_{i=1}^I p_{ij}$$

- Coldist (Distâncias Qui-Quadrado das Colunas)

Descrição: distância qui-quadrado entre cada perfil de coluna e o perfil médio das linhas.

Fórmulas:

$$d_j^2 = \sum_{i=1}^I \frac{\left(\frac{p_{ij}}{c_j} - r_i \right)^2}{r_i}$$

- Colinertia (Inércia das Colunas)

Descrição: contribuição absoluta de cada coluna para a inércia total.

Fórmulas:

$$I_j = c_j d_j^2$$

A inércia total também pode ser escrita como:

$$I = \sum_j c_j d_j^2$$

- Colcodd (Coordenadas das Colunas)

Descrição: coordenadas fatoriais das categorias de coluna nos eixos da análise.

Fórmulas:

$$\mathbf{G} = \mathbf{D}_c^{-1/2} \mathbf{V}$$

- N (Tabela de Frequências)

Descrição: matriz de contingência original utilizada como entrada da Análise de Correspondência.

Fórmulas:

$$\mathbf{N} = \begin{bmatrix} n_{11} & n_{12} & \cdots & n_{1J} \\ n_{21} & n_{22} & \cdots & n_{2J} \\ \vdots & \vdots & \ddots & \vdots \\ n_{I1} & n_{I2} & \cdots & n_{IJ} \end{bmatrix}$$

onde n_{ij} representa a frequência observada na célula (i, j) .

Em R:

```
A <- ca(N)

P <- A$N / sum(A$N)

r <- rowSums(P)
c <- colSums(P)

Dr <- diag(r)
Dc <- diag(c)

S <- solve(sqrt(Dr)) %*%
      (P - r %*% t(c)) %*%
      solve(sqrt(Dc))

svdS <- svd(S)

sv <- svdS$d

rowcoord <- solve(sqrt(Dr)) %*%
              svdS$u %*%
              diag(sv)
```

```
colcoord <- solve(sqrt(Dc)) %*%  
            svdS$v %*%  
            diag(sv)  
  
rowdist <- sqrt(rowSums((rowcoord^2)))  
  
coldist <- sqrt(colSums(t(colcoord)^2))  
  
rowinertia <- r * rowdist^2  
  
colinertia <- c * coldist^2
```

1.2 Questão 73

O pacote `vcd` do R possui dados sobre sobre suicídio na Alemanha Ocidental obtidos de Heuer, J., 1979 (Suicide by children and youth). O arquivo possui 306 observações e 6 variáveis:

- `Freq`: número de casos.
- `sex`: sexo masculino (male) e feminino (female)
- `method`: método de suicídio - poison (envenenamento), toxic gas (gás tóxico), cooking gas (gás de cozinha), hang (enforcamento), drown (afogamento), gun (arma de fogo), knife (faca), jump (pulo) e other (outros).
- `age`: idade.
- `age.group`: faixa etária.
- `method2`: método de suicídio. Igual a `method`, mas com as categorias toxic gas e cooking gas unidas como gas. Observação: neste caso você tem uma tabela com três variáveis, i.e., (sexo, método, grupo de idade).

Realize uma análise de correspondências com as variáveis `method` e `age.group`.

a) Indique cada etapa de seu estudo e respectivas conclusões.

1 - Etapa: Carregar os dados e preparar a tabela de contingência

Carregando pacotes exigidos: `grid`

Tabela 1: Tabela de contingência entre método e faixa etária

	10-20	25-35	40-50	55-65	70-90
poison	2081	4495	4689	3814	2486
cookgas	45	83	53	38	34
toxicgas	330	913	663	208	40
hang	1736	3326	5417	5595	4303
drown	97	352	601	886	713
gun	537	916	927	506	232
knife	58	180	263	257	179
jump	320	642	571	661	651
other	564	1038	839	590	253

2 - Etapa: Verificação de Fatorabilidade

Teste Qui-Quadrado sob as seguintes hipóteses:

H_0): As variáveis são independentes (não há associação)

H_1): Existe associação

Tabela 2: Teste Qui-Quadrado - Dados VCD

	Estatística	GL	Valor.p
X-squared	3462.211	32	< 2.2e-16

Dado o p – valor de 0 (muito menor que 0.05), a hipótese nula é rejeitada. Logo, estatisticamente a escolha do método de suicídio está relacionado com a idade da pessoa.

3 - Execução da análise de correspondências (AC)

```
resultado_ca <- ca(tabela_contingencia)

summary(resultado_ca)
```

Principal inertias (eigenvalues):

dim	value	%	cum%	scree plot
1	0.060847	93.5	93.5	*****
2	0.002249	3.5	96.9	*
3	0.001649	2.5	99.5	*
4	0.000356	0.5	100.0	

Total:		0.065101	100.0	

Rows:

	name	mass	qlt	inr	k=1 cor	ctr	k=2 cor	ctr
1	posn	330	985	55	-103	985 58	0	0 0
2	ckgs	5	979	10	-318	719 8	191	260 78
3	txcg	41	961	260	-633	959 266	-27	2 13
4	hang	383	993	233	197	980 245	-23	13 89
5	drwn	50	966	148	431	962 152	27	4 16
6	gun	59	953	124	-360	941 125	-41	12 44
7	knif	18	831	10	158	707 7	-66	124 34
8	jump	53	978	31	89	209 7	171	769 695
9	othr	62	963	129	-361	954 132	34	8 31

Columns:

	name	mass	qlt	inr	k=1 cor	ctr	k=2 cor	ctr
1	1020	108	893	160	-290	878 150	37	14 66
2	2535	225	974	319	-298	962 328	34	13 116
3	4050	264	963	26	-39	239 7	-69	725 554
4	5565	236	981	165	211	977 172	-13	4 19
5	7090	167	996	330	353	970 343	57	26 246

Como é possível observar pela saída da função `ca()`, a inércia total de 0.065101 confirma a existência de uma estrutura de dados “não aleatória” a ser explorada. Sem inércia (ou com inércia próxima de zero), os perfis seriam homogêneos, o teste Qui-Quadrado não seria significativo e os pontos estariam todos sobrepostos na origem do gráfico, tornando a análise inútil.

A primeira dimensão explica, sozinha, 93.47% da inércia total. Portanto, o mapa bidimensional será adequado, uma vez que, usando duas dimensões, a perda de informação é de apenas 3.1%.

Tabela 3: Resíduos de Pearson

	10-20	25-35	40-50	55-65	70-90
poison	4.03	8.75	0.84	-5.17	-8.31
cookgas	3.35	3.47	-1.68	-2.81	-1.28
toxicgas	6.31	19.51	3.99	-13.33	-16.87
hang	-10.08	-18.49	0.60	11.31	15.36
drown	-11.23	-9.96	-3.69	10.42	12.84
gun	10.81	8.15	3.66	-8.48	-12.67
knife	-4.33	-2.10	1.01	2.41	1.79
jump	0.65	0.12	-6.54	-0.41	8.04
other	11.01	11.06	-0.91	-6.65	-12.63

4 - Interpretação da análise

b) Calcule e interprete a estatística Qui-Quadrado e a Inércia Total.

O teste Qui-Quadrado apresentou um p-valor extremamente baixo ($p < 0.001$), permitindo rejeitar a hipótese de independência e confirmar uma associação estatisticamente significativa entre método de suicídio e faixa etária. A Inércia Total de 0.065101 quantifica essa associação global, fornecendo a base necessária para a decomposição em dimensões e a construção do mapa perceptual.

c) Análise os resíduos em cada célula da tabela e interprete os resultados.

Análise por faixa:

- 10-20 anos: apresenta associação negativa aos métodos de afogamento e enforcamento, positiva e predominante para “Outros” e armas, seguida de gás tóxico, envenenamento e gás de cozinha;
- 25-35 anos: associação positiva para gás tóxico, “Outros”, envenenamento, armas, gás de cozinha, e, próximo de 0, pular. Associação negativa para enforcamento, sendo a maior da tabela, seguida de afogamento e facas;
- 40-50 anos: apresenta associação positiva para gás tóxico e armas, seguida de facas, envenenamento e enforcamento (quase nula). Apresenta associação negativa predominante para pular, seguida de afogamento e gás de cozinha;
- 55-65 anos: associação positiva para enforcamento e afogamento, seguido de pulo e facas; associação negativa para gás tóxico, armas e “Outros”, seguida de envenenamento, e gás de cozinha;
- 70-90 anos: associação positiva e predominante para enforcamento, afogamento, pular e facas; associação negativa extrema para gás tóxico, armas, “Outros” e envenenamento.

Principais Associações Positivas:

- Gás Tóxico e Jovens Adultos (25-35 anos): O resíduo de 19.51 é o mais alto da tabela, indicando uma concentração massiva deste método nesta faixa etária específica.
- Enforcamento e Idosos (70-90 anos): Com um resíduo de 15.36, há uma forte associação entre idades avançadas e o método de enforcamento.
- Armas de Fogo e Jovens (10-20 anos): O valor de 10.81 mostra que este método é característico dos grupos mais jovens na amostra alemã.
- Outros Métodos e Jovens (10-35 anos): Resíduos acima de 11 indicam que métodos não classificados nos tradicionais são prevalentes em indivíduos mais novos.


Principais Associações Negativas:

- Enforcamento e Jovens Adultos (25-35 anos): O resíduo de -18.49 é uma repulsão fortíssima. Embora o enforcamento seja comum no geral, este grupo de idade o utiliza muito menos do que a média da população.
- Gás Tóxico e Idosos (55-90 anos): Resíduos de -13.33 e -16.87 indicam que o uso de gás tóxico é extremamente raro entre os mais velhos.
- Afogamento e Jovens (10-20 anos): O valor de -11.23 mostra que este método é significativamente menos frequente na juventude.

A análise dos resíduos de Pearson confirma que a escolha do método de suicídio é fortemente condicionada pela idade. Destaca-se a atração extrema entre o grupo de 25-35 anos e o uso de gás tóxico ($\epsilon = 19.51$), enquanto o enforcamento mostra uma transição clara: é fortemente rejeitado pelos jovens adultos ($\epsilon = -18.49$) e predominante entre os idosos acima de 70 anos ($\epsilon = 15.36$). Esses desvios da independência são os elementos que estruturam as dimensões da análise e posicionarão esses grupos em extremidades opostas no mapa de correspondências.

d) Apresente um mapa de correspondências e faça um breve resumo dos resultados gerais da análise.

Figura 1: Mapa de Correspondências: Método vs Faixa Etária



Os Resíduos de Pearson da tabela Tabela 3 e o gráfico Figura 1 denotam a mesma informação, existe uma forte associação entre o método de suicídio e a faixa etária, sendo a primeira dimensão responsável por 93.47% da inércia total. Portanto, a maior parte da estrutura dos dados pode ser interpretada ao longo do eixo horizontal do Figura 1.

Os resíduos mostram que os métodos mais associados aos jovens são:

- gás tóxico (19.51 para 25–35 anos e 6.31 para 10–20 anos);
- “Outros” (11.06 e 11.01);
- armas (8.15 e 10.81);
- envenenamento (8.75 e 4.03);
- gás de cozinha (3.47 e 3.35).

Esses métodos aparecem no lado esquerdo do mapa, próximos das faixas etárias 10–20 e 25–35.

Por outro lado, os métodos mais associados aos idosos são:

- enforcamento (15.36 para 70–90 anos e 11.31 para 55–65 anos);
- afogamento (12.84 para 70–90 anos e 10.42 para 55–65 anos);
- pular (8.04 para 70–90 anos).

Conclusão:

A análise evidencia que o método de suicídio utilizado varia substancialmente conforme a faixa etária. Indivíduos jovens apresentam associação com envenenamento, gases tóxicos, armas de fogo e outros métodos, enquanto indivíduos mais velhos estão mais associados ao enforcamento, afogamento e pular. Como a primeira dimensão explica 93,5% da inércia, essa oposição entre jovens e idosos constitui a principal estrutura presente nos dados.

1.3 Questão 6.1 Artes e Barroso

Dados: Covid19SP.xlsx

Tabela 4: Variáveis disponíveis para municípios de São Paulo

Variável	Descrição
Código	Código do município (codificação própria)
Município	Nome do município
GrupoPop	Grupo por faixa da população (P1 a P4)
Casos	Casos de Covid-19 notificados até 18/06/2021
Óbitos	Óbitos por Covid-19 notificados até 18/06/2021
População	População estimada em 2021
IDHM	Índice de Desenvolvimento Humano Municipal em 2010
IDHR	Índice de Desenvolvimento Humano Renda em 2010
IDHL	Índice de Desenvolvimento Humano Longevidade em 2010
IDHE	Índice de Desenvolvimento Humano Educação em 2010
Prevalência	Casos de Covid-19 por 1.000 habitantes até 18/06/2021
Mortalidade	Óbitos por Covid-19 por 10.000 habitantes até 18/06/2021
Letalidade	Óbitos por Covid-19 por 100 casos até 18/06/2021
HabDom	Número médio de habitantes por domicílio
GrauUrb	Grau de urbanização, em porcentagem

a) Categorize as variáveis Prevalência, Mortalidade e Letalidade com base em seus quartis.

Por meio da função `quantile()` as variáveis em questão foram categorizadas da

seguinte maneira:

- Baixa: Valores entre o Mínimo e Q1.
- Média-Baixa: Valores entre Q1 e Q2.
- Média-Alta: Valores entre Q2 e Q3.
- Alta: Valores entre Q3 e o Máximo.

```
library(readxl)

dados <- read_xlsx(path = "COVID19SP\\COVID19SP.xlsx")

dados$Prevalencia_cat <- cut(dados$Prevalência,
                             breaks = quantile(dados$Prevalência,
                                                  probs = seq(0, 1, 0.25),
                                                  na.rm = TRUE),
                             labels = c("Baixa", "Média-Baixa",
                                          "Média-Alta", "Alta"),
                             include.lowest = TRUE)

dados$Mortalidade_cat <- cut(dados$Mortalidade,
                             breaks = quantile(dados$Mortalidade,
                                                  probs = seq(0, 1, 0.25),
                                                  na.rm = TRUE),
                             labels = c("Baixa", "Média-Baixa",
                                          "Média-Alta", "Alta"),
                             include.lowest = TRUE)

dados$Letalidade_cat <- cut(dados$Letalidade,
                             breaks = quantile(dados$Letalidade,
                                                  probs = seq(0, 1, 0.25),
                                                  na.rm = TRUE),
                             labels = c("Baixa", "Média-Baixa",
                                          "Média-Alta", "Alta"),
                             include.lowest = TRUE)
```

b) Faça os mapas da análise de correspondência simples de cada uma das variáveis categorizadas no item a) versus a variável GrupoPop. Interprete os resultados.

Prevalência X GrupoPop

Lembrando que a variável *Prevalencia* é “Casos de Covid-19 por 1.000 Habitantes”. A partir da figura Figura 2, é possível notar que a Dimensão 1 explica 75.8% da inércia, ou seja, ela é a principal responsável pela associação.

O grupo P2 apresentou associação com as categorias intermediárias de prevalência (Média-Baixa e Média-Alta), enquanto P1 esteve mais associado à categoria Baixa e P4 à categoria Alta. O grupo P3 apresentou associação moderada com a categoria Média-Alta. As associações observadas foram moderadas, uma vez que os resíduos padronizados não ultrapassaram o valor absoluto de 2.

Mortalidade X GrupoPop

Lembrando que a variável *Mortalidade* é “Casos de Covid-19 por 10.000 Habitantes”.

Figura 2: Mapa de Correspondências: Prevalência vs Faixa GrupoPop






Figura 3: Mapa de Correspondências: Mortalidade vs Faixa GrupoPop



A partir da figura Figura 3, é possível notar que a Dimensão 1 explica 78.3% da inércia, ou seja, ela é a principal responsável pela associação.

O grupo P4 esteve associado à categoria Baixa, enquanto P2 apresentou associação com a categoria Média-Alta. O grupo P1 mostrou comportamento oposto à categoria Baixa, indicando tendência a mortalidades mais elevadas, ao passo que P3 apresentou associação moderada com as categorias Baixa e Média-Baixa. Algumas associações foram relativamente fortes, com resíduos padronizados superiores a 2 em valor absoluto.

Figura 4: Mapa de Correspondências: Letalidade vs Faixa GrupoPop



A partir da figura Figura 4, é possível notar que a Dimensão 1 explica 62.6% da inércia total, ou seja, ela é a principal responsável pela associação.

O grupo P1 apresentou associação com as categorias Média-Alta e Alta, enquanto P2 esteve associado à categoria Média-Baixa. O grupo P4 mostrou associação com a categoria Baixa, ao passo que P3 apresentou associação com as categorias Baixa e Média-Baixa e associação negativa com a categoria Alta. As associações observadas foram relativamente fortes, uma vez que diversos resíduos padronizados ultrapassaram o valor absoluto de 2.

c) Faça a análise de correspondência múltipla das quatro variáveis consideradas no item b).


```
library(dplyr)
```

```
dados_acm <- dados %>% select(GrupoPop, Prevalencia_cat, Mortalidade_cat, Letalidad
```

```
resultado_acm <- mja(dados_acm)
```

```
plot(resultado_acm)
```

Figura 5: Mapa de Correspondências: Múltipla GrupoPop - Prev, Mort, Letal



d) Compare as análises feitas nos itens b) e c)

1.4 Questão 6.2 Artes e Barroso

Tabela 5: Características de mochilas e de escoliose

Variável	Descrição
Sexo	Sexo da criança – M: masculino, F: feminino
Peso	Peso da criança em quilogramas
Altura	Altura da criança em metros
TipoMochila	Tipo da mochila – E: escapular, L: lateral, C: carrinho
ModoCarregar	Modo de carregar a mochila – 1: dois ombros, 2: um ombro, 3: no tronco, 4: mão direita, 5: mão esquerda, 6: outros
Escoliose	Lado da escoliose – D: direito, E: esquerdo, A: ausente

a) Faça uma análise de correspondência simples considerando as variáveis **Tipo-Mochila** e **Escoliose**. Comente.

```
dados <- read_xlsx(path = "MOCHILA\\MOCHILA.xlsx")

dados$TipoMochila_cat <- c(
  "E" = "Escapular",
  "L" = "Lateral",
  "C" = "Carrinho"
)[dados$TipoMochila]


dados$Escoliose_cat <- c(
  "D" = "Direito",
  "E" = "Esquerdo",
  "A" = "Ausente"
)[dados$Escoliose]

N <- table(dados$TipoMochila_cat, dados$Escoliose_cat)

resultado <- ca(N)

plot(resultado)
```


Figura 6: Mapa de Correspondências: Tipo Mochila X Escoliose



Observa-se na figura Figura 6, que mochilas de carrinho estão associadas a escoliose-direita, enquanto lateral parece distante sem associações claras. Já as mochilas escapulares estão associadas a escoliose-esquerda e à ausência de escoliose. Ademais, é possível observar também que a Dimensão 1 explica 99.1% da inércia total.

b) Agrupe as categorias da variável ModoCarregar em três categorias (1: nos dois ombros + no tronco, 2: em um ombro + na mão direita + na mão esquerda, 3: outros) e com elas faça uma análise de correspondência simples versus Escoliose. Comente.


```
dados <- dados %>%
  mutate(
    ModoCarry = case_when(
      ModoCarregar == 1 ~ "nos dois ombros + no tronco",
      ModoCarregar == 2 ~ "em um ombro + na mão direita + na mão esquerda",
      TRUE ~ "outros"
    )
  )

Ncarry <- table(dados$ModoCarry, dados$Escoliose_cat)

res_carry <- ca(Ncarry)

plot(res_carry)
```

Figura 7: Mapa de Correspondências: ModoCarregar X Escoliose



Como é possível notar na Figura Figura 7, os modos de carregar a mochila nos dois ombros e no tronco estão associados à escoliose do lado esquerdo, enquanto a categoria Outros apresenta associação com a escoliose do lado direito. Por outro lado, os modos de carregar em um ombro, na mão direita e na mão esquerda, bem como a ausência de escoliose, não apresentaram associações específicas tão evidentes. Além disso, essas categorias encontram-se relativamente afastadas da origem, indicando perfis distintos em relação ao perfil médio observado na tabela. Ademais, nota-se que a Dimensão 1 explica 89.9% da inércia total.

c) Faça uma análise de correspondência para avaliar Escoliose versus TipoMochila e ModoCarregar, usando tabelas combinadas.

```
tab1 <- table(dados$TipoMochila_cat, dados$Escoliose_cat)


tab2 <- table(dados$ModoCarry, dados$Escoliose_cat)

tab_comb <- rbind(tab1, tab2)

res_comb <- ca(tab_comb)

plot(res_comb)
```


Figura 9: Mapa de Correspondências: Escoliose X Tipo Mochila e ModoCarregar - Justapostas



O gráfico da figura Figura 9 apresenta que o tipo de mochila carrinho está associado com escoliose direita, enquanto tipo mochila lateral está associada com escoliose direita e modo de carregar. Os outros pontos estão distantes entre si de maneira que nenhuma associação está clara.

e) Compare todas as análises feitas.

As análises de correspondência indicam uma estrutura de associação consistente entre escoliose e padrões de uso de mochila. Observa-se que a associação mais robusta e estável ao longo de todas as abordagens refere-se ao uso de mochilas tipo carrinho, associado à escoliose direita, e ao uso de dois ombros/tronco, associado à escoliose esquerda. Entretanto, categorias com menor frequência ou maior granularidade (como “lateral”, “escapular” e “outros”) apresentam instabilidade de posicionamento nos mapas fatoriais, o que é esperado devido à baixa contribuição relativa dessas categorias na inércia total e à sensibilidade da análise ao nível de agregação das variáveis. Adicionalmente, observa-se que as análises com variáveis combinadas tendem a concentrar maior proporção da inércia na primeira dimensão, refletindo uma estrutura mais unidimensional das associações.


1.5 Questão 6.3 Artes e Barroso

Tabela 6: Tabela de contingência: cor dos olhos versus cor dos cabelos

Olhos.Cabelos	Loiro	Vermelho	Castanho.claro	Castanho.escur	Preto	Total
Verde	688	116	584	188	4	1580
Azul	326	38	241	110	3	718
Castanho	343	84	909	412	26	1774
Preto	98	48	403	681	85	1315
Total	1455	286	2137	1391	118	5387

a) Faça os mapas da análise de correspondência simples de cor dos olhos versus cor dos cabelos em duas dimensões. Interprete os resultados.

Figura 10: Mapa de Correspondências: Cor dos olhos X Cor dos cabelos



Como é possível observar na figura Figura 10, olhos Pretos possuem associação com cabelos Castanho-Escuro e Pretos, olhos Castanhos com cabelos Castanho-claro, e olhos Azuis e Verdes com cabelos Vermelhos e Loiros.

b) Qual é a porcentagem da inércia principal explicada por cada um dos eixos?

Como observado na figura Figura 10, a dimensão 1, eixo x, explica 86.6% da inércia total, já a dimensão 2, 13.1%

c) Qual é a qualidade da representação de cada categoria de cor de olhos e de cor dos cabelos?

```
summary(res_olhoxcabelo)
```

Principal inertias (eigenvalues):

dim	value	%	cum%	scree plot
1	0.199245	86.6	86.6	*****
2	0.030087	13.1	99.6	***
3	0.000859	0.4	100.0	

Total: 0.230191 100.0				

Rows:

	name	mass	qlt	inr	k=1 cor	ctr	k=2 cor	ctr
1	Verd	293	995	259	441	956 286	88	39 76
2	Azul	133	979	111	400	836 107	165	143 121
3	Cstn	329	999	88	-34	18 2	-245	981 657
4	Pret	244	1000	543	-703	965 605	134	35 145

Columns:

	name	mass	qlt	inr	k=1 cor	ctr	k=2 cor	ctr
1	Loir	270	1000	383	544	907 401	174	93 271
2	Vrml	53	803	16	233	770 14	48	33 4
3	Cstnhc	397	1000	78	42	39 4	-208	961 572
4	Cstnhs	258	1000	401	-589	969 449	104	30 93
5	Pret	22	998	122	-1094	934 132	286	64 60

Através da função `summary()`, observou-se que as categorias de cor dos olhos apresentaram excelente qualidade de representação nas duas primeiras dimensões, com valores superiores a 0,97. Para a cor dos cabelos, as categorias Loiro, Castanho-claro, Castanho-escuro e Preto também apresentaram excelente representação, com qualidade próxima de 1,00, enquanto a categoria Vermelho apresentou qualidade ligeiramente inferior (0,803), embora ainda satisfatória. Dessa forma, o plano bidimensional representa adequadamente as associações entre as categorias analisadas, uma vez que as duas primeiras dimensões explicam aproximadamente 99,7% da inércia total.

d) Qual é a cor de olhos e cor dos cabelos que mais explicam as inércias dos eixos do mapa? De quanto?

Na primeira dimensão, a categoria de cor dos olhos que mais contribuiu para a formação do eixo foi Preto (60,5%), enquanto, para a cor dos cabelos, a maior contribuição foi da categoria Castanho-escuro (44,9%). Na segunda dimensão, a categoria Castanho foi a principal responsável pela inércia entre as cores dos olhos (65,7%), ao passo que a categoria Castanho-claro apresentou a maior contribuição entre as cores dos cabelos (57,2%).

e) Qual é a contribuição dos eixos para cada categoria de cor de olhos? E de cor dos cabelos?

A primeira dimensão explicou a maior parte da variabilidade das categorias Verde (95,6%), Azul (83,6%) e Preto (96,5%) da cor dos olhos, bem como das categorias Loiro

(90,7%), Vermelho (77,0%), Castanho-escuro (96,9%) e Preto (93,4%) da cor dos cabelos. Por outro lado, a categoria Castanho dos olhos (98,1%) e a categoria Castanho-claro dos cabelos (96,1%) foram explicadas predominantemente pela segunda dimensão.

1.6 Questão 6.4 Artes e Barroso

a) Faça os mapas da análise de correspondência simples do “Motivo do crédito” (X4) versus “Sexo” e “Estado civil” (X9). Interprete os resultados.

```
dados <- read_xlsx(path = "BancoAlemao\\BancoAlemao.xlsx")

dados$X9_cat <- c(
  NA,
  "M-divorciado/separado",
  "F-divorciada/separada/casada",
  "M-solteiro",
  "M-casado/viúvo",
  "F-solteira"
)[dados$X9 + 1]


dados$X4_cat <- c(
  "Carro zero",
  "Carro usado",
  "Móvel",
  "Rádio/TV",
  "Aparelhos domésticos",
  "Reparos",
  "Educação",
  "Viagem/Férias",
  "Cursos",
  "Negócios",
  "Outros"
)[dados$X4 + 1]

N64 <- table(dados$X4_cat, dados$X9_cat)

res_64 <- ca(N64)

plot(res_64)
```

Figura 11: Mapa de correspondências - Motivo do crédito X Sexo e estado Civil



Observa-se na figura Figura 11 que a Dimensão 1 explica 50.8% da inércia total, e a Dimensão 2, 30.8%. Ademais, é possível notar que Homens solteiros possuem associação com Reparos, Carro usado, Carro zero, Negócios, enquanto Homens divorciados/separados possuem associação com Outros. Mulheres divorciadas/separadas/casadas possuem mais associação com Educação, Aparelhos Domésticos, Móveis. Por fim, o homem casado/viúvo tem mais associação com Rádio/tv e Cursos.

b) Faça os mapas da análise de correspondência simples do “Motivo do crédito” (X4) versus “Ocupação” (X17). Interprete os resultados.

X17 tem valores únicos de 1,2,3,4, que não batem com o dicionário do livro. Assumirei que o valor 5 do dicionário é o 4 do banco de dados.

```
dados$X17_cat <- c(
  "1" = "Desempregado/não qualificado/não residente",
  "2" = "Não qualificado/residente",
  "3" = "Qualificado",
  "4" = "Gestor/autônomo/altamente qualificado"
```




```
)[as.character(dados$X17)]

N64_b <- table(dados$X4_cat, dados$X17_cat)

res_64_b <- ca(N64_b)

plot(res_64_b)
```

Figura 12: Mapa de correspondências - Motivo do crédito X Ocupação



Observa-se na figura Figura 12 que a Dimensão 1 explica 65.7% da inércia total, e a Dimensão 2, 26.2%. Além disso, é possível notar que Gestores/autônomos/altamente qualificados são associados à Carros usados, Educação, Negócios, Móveis, Rádios/TV, Carro zero, de maneira muito similar, com exceção de Carro usado, com os Qualificados. Os Não qualificados/residentes são associados a Carro zero, Cursos, Reparos e Aparelhos domésticos, e os Desempregados/não qualificados/não responderam estão um pouco distantes na dimensão 2 do restante das ocupações, porém estão em posição semelhante à Qualificados na Dimensão 1.


c) Faça a análise de correspondência para tabelas justapostas considerando “Motivo do crédito” (X4) versus “Sexo” e “Estado civil” (X9) e “Ocupação” (X17).

```
tab_64just <- cbind(N64, N64_b)

res_64just <- ca(tab_64just)

plot(res_64just)
```

Figura 13: Mapa de correspondências - Motivo do crédito X Ocupação X Sexo



A análise de correspondência para tabelas justapostas apresentada na Figura 13 indicou que a Dimensão 1 explicou 49,2% da inércia total, enquanto a Dimensão 2 explicou 19,9%. De modo geral, as categorias encontram-se próximas da origem do mapa perceptual, sugerindo perfis semelhantes e associações pouco pronunciadas entre as variáveis analisadas. Dessa forma, a interpretação deve concentrar-se nas categorias mais distantes da origem. As categorias Desempregado/não qualificado/não residente, Homens casados/viúvos, Cursos e Outros apresentaram maior afastamento em relação ao centro do

gráfico, indicando perfis mais distintos da média e maior contribuição para a estrutura de associação observada.

d) Compare as análises feitas nos itens a), b) e c).

As análises dos itens a), b) e c) forneceram perspectivas complementares sobre a associação entre os motivos do crédito e as variáveis socioeconômicas. Na análise envolvendo sexo e estado civil, observou-se uma diferenciação mais clara entre os grupos, com associações específicas entre determinadas categorias e os motivos do crédito. Na análise envolvendo ocupação, as associações mostraram-se mais estruturadas, destacando a proximidade entre ocupações qualificadas e diversos tipos de crédito, enquanto os desempregados apresentaram perfil distinto em relação às demais categorias.

Por sua vez, a análise de correspondência para tabelas justapostas permitiu avaliar simultaneamente as variáveis sexo/estado civil e ocupação em relação aos motivos do crédito. Entretanto, a maior concentração das categorias próximas à origem indicou perfis mais semelhantes e associações menos pronunciadas quando consideradas conjuntamente. Ainda assim, algumas categorias, como Desempregado/não qualificado/não residente, Homens casados/viúvos, Cursos e Outros, destacaram-se por apresentarem maior afastamento da origem, contribuindo mais para a estrutura de associação observada.

Dessa forma, as análises separadas permitiram identificar associações específicas com maior clareza, enquanto a análise justaposta forneceu uma visão global das relações entre as variáveis, evidenciando os perfis mais distintos no conjunto dos dados

1.7 Questão 6.5 Artes e Barroso

a) Agrupe o número de habitantes de acordo com as seguintes faixas etárias: até 17 anos, de 18 a 29 anos, de 30 a 49, de 50 a 64 e 65 ou mais anos. Faça os mapas da análise de correspondência simples de região versus faixa etária. Interprete os resultados.

```
populacao <- data.frame(
  Etaria = c("0 a 4 anos", "5 a 13 anos", "14 a 17 anos", "18 a 19 anos",
            "20 a 24 anos", "25 a 29 anos", "30 a 39 anos", "40 a 49 anos",
            "50 a 59 anos", "60 a 64 anos", "65 anos ou mais", "Total"),
  Norte = c(1591, 2771, 1337, 642, 1683, 1704, 2951, 2363, 1693, 613, 1231, 18579),
  Nordeste = c(4136, 7832, 3711, 1798, 4830, 4695, 9099, 7848, 6046, 2202, 5325, 57),
  Sudeste = c(5593, 10028, 4717, 2433, 6961, 6766, 14390, 12983, 10831, 4605, 10304),
  Sul = c(2037, 3516, 1589, 776, 2181, 2392, 4983, 4209, 3773, 1560, 3343, 30359),
  C_Oeste = c(1300, 2132, 954, 491, 1349, 1401, 2730, 2359, 1816, 661, 1388, 16581),
  Total = c(14657, 26279, 12308, 6140, 17004, 16958, 34153, 29762, 24159, 9641, 215)
)

populacao$nova_faixa <- c(
  "até 17 anos",      # 0-4
  "até 17 anos",      # 5-13
  "até 17 anos",      # 14-17
  "18 a 29 anos",     # 18-19
  "18 a 29 anos",     # 20-24
  "18 a 29 anos",     # 25-29
  "18 a 29 anos",     # 30-39
  "18 a 29 anos",     # 40-49
  "18 a 29 anos",     # 50-59
  "18 a 29 anos",     # 60-64
  "18 a 29 anos",     # 65 ou mais
  "Total"
)
```

```
"30 a 49 anos",      # 30-39
"30 a 49 anos",      # 40-49
"50 a 64 anos",      # 50-59
"50 a 64 anos",      # 60-64
"65 ou mais anos",   # 65+
NA                   # Total (vai ser removido)
)

populacao <- subset(populacao, !is.na(nova_faixa))

tab <- populacao %>%
  group_by(nova_faixa) %>%
  summarise(
    Norte = sum(Norte),
    Nordeste = sum(Nordeste),
    Sudeste = sum(Sudeste),
    Sul = sum(Sul),
    C_Oeste = sum(C_Oeste)
  )


rownames(tab) <- tab$nova_faixa
matriz <- as.matrix(tab[, -1])

rownames(matriz) <- as.character(tab$nova_faixa)
colnames(matriz) <- colnames(tab)[-1]

res <- ca(matriz)

plot(res)
```

Figura 14: Mapa de correspondências - Região X Faixa Etária



Observa-se, por meio da Figura 14, uma estrutura de associação entre regiões e faixas etárias, com predominância explicativa da primeira dimensão. Nota-se que as regiões Sul e Sudeste apresentam maior proximidade com as faixas etárias de 30 a 49 anos e 50 a 64 anos, sugerindo um perfil etário mais envelhecido em comparação às demais regiões. Por outro lado, as regiões Nordeste e Centro-Oeste tendem a se aproximar das faixas etárias mais jovens, especialmente até 17 anos e de 18 a 29 anos, indicando uma estrutura demográfica relativamente mais jovem nesses agrupamentos. A faixa etária de 65 anos ou mais, assim como a região Norte, encontram-se mais próximas da origem do plano fatorial, o que indica um perfil mais próximo da média global, sem associações fortes com categorias específicas no espaço bidimensional.

\textbf{b) Quantos eixos seriam necessários para explicar 100% da inércia total? }

Por meio da função `summary()`, quando utilizada na saída da função `ca()`, é possível entender quantos % da inércia total são explicados por cada dimensão.

```
summary(res)
```

Principal inertias (eigenvalues):

dim	value	%	cum%	scree plot
1	0.007695	97.6	97.6	*****
2	0.000118	1.5	99.1	

```

3      5.1e-050    0.6  99.8
4      1.7e-050    0.2 100.0
-----
Total: 0.007880 100.0

```

Rows:

	name	mass	qlt	inr	k=1 cor	ctr	k=2 cor	ctr
1	1829	189	972	96	-62	969 95	-4	3 20
2	3049	301	886	18	19	763 14	8	123 146
3	5064	159	993	234	107	979 235	13	14 216
4	65ms	102	1000	302	151	971 301	-26	29 587
5	at17	250	994	350	-105	992 356	-4	1 32

Columns:

	name	mass	qlt	inr	k=1 cor	ctr	k=2 cor	ctr
1	Nort	87	998	416	-193	997 425	5	1 17
2	Nrds	270	996	163	-68	969 162	-11	27 295
3	Sdst	421	995	296	74	994 301	-2	1 20
4	Sul	143	943	77	62	921 72	10	23 117
5	C_0s	78	974	48	-63	803 40	29	170 551

Logo, com 4 dimensões seria possível explicar 100% da inércia total.

c) Qual é a porcentagem da inércia principal explicada por cada um dos eixos?

- Dimensão 1: 97.6%
- Dimensão 2: 1.5%
- Dimensão 3: 0.6%
- Dimensão 4: 0.2%

d) Qual é a qualidade da representação de cada categoria de região e de faixa etária?

Observa-se que, de modo geral, tanto as regiões quanto as faixas etárias apresentam alta qualidade de representação no plano fatorial, com valores de qlt predominantemente acima de 0,94, indicando que suas posições no mapa são bem explicadas pelas duas dimensões.

e) Qual é a região que mais explica a inércia dos eixos do mapa? De quanto?

A região que mais contribui para a formação da Dimensão 1 é o Norte, com contribuição de aproximadamente 425, sendo a principal responsável pela estrutura de separação observada no eixo. Já na Dimensão 2, a maior contribuição é da região Centro-Oeste, com valor de aproximadamente 551, indicando que esta região é a principal responsável pela variabilidade capturada no segundo eixo do mapa fatorial.

f) Qual é a contribuição dos eixos para cada categoria de faixa etária?

As contribuições das faixas etárias indicam que a Dimensão 1 é fortemente influenciada pelas categorias “até 17 anos”, “18 a 29 anos” e “65 anos ou mais”, sendo estas as principais responsáveis pela estrutura de separação observada no eixo horizontal do mapa.

Já a Dimensão 2 é majoritariamente determinada pela faixa etária de “65 anos ou mais”, seguida pelas faixas “50 a 64 anos” e “14 a 17 anos”, indicando que o segundo eixo capta variações mais específicas relacionadas ao envelhecimento populacional.

1.8 Questão 6.6 Artes e Barroso

1.9 Questão 6.7 Artes e Barroso

1.10 Questão 6.8 Artes e Barroso

1.11 Questão 6.9 Artes e Barroso